

Proyecto Final

Soluciones Intensivas en Datos (2026-20)

Entrega 1

OceanWatch Analytics: el lakehouse del tráfico marítimo

Proyecto final · 30% de la nota del curso · Grupos de 3 · Dos entregas

1. Contexto

Ustedes son el equipo de datos de **OceanWatch Analytics**, el operador analítico que las autoridades portuarias y las navieras contratan para entender el tráfico marítimo: qué buques pasan, por dónde, a qué velocidad y cuánto tiempo permanecen en puerto.

Los buques mercantes transmiten su posición de forma continua mediante el **AIS** (Automatic Identification System): identificador, posición, velocidad, rumbo y características del buque, mensaje a mensaje. La NOAA publica todo ese tráfico para las aguas de Estados Unidos en archivos diarios.

En la **primera fase** del proyecto explorarán esos datos, responderán las preguntas que hace el negocio y los dejarán almacenados de forma óptima para el propósito acordado.

2. Los datos

- **Fuente oficial:** AIS Data de Marine Cadastre (NOAA). Un archivo zip por día, con un CSV de posiciones adentro. Documentación del dataset y del estándar AIS: <https://hub.marinecadastre.gov/pages/vesseltraffic>
- **Corpus de la Entrega 1:** los días **1 al 7 de junio de 2023** (7 archivos, ~2,3 GB comprimidos en total, del orden de 150 millones de filas). Enlaces directos:
 - https://coast.noaa.gov/htdata/CMSP/AISDataHandler/2023/AIS_2023_06_01.zip
 - https://coast.noaa.gov/htdata/CMSP/AISDataHandler/2023/AIS_2023_06_02.zip
 - https://coast.noaa.gov/htdata/CMSP/AISDataHandler/2023/AIS_2023_06_03.zip
 - https://coast.noaa.gov/htdata/CMSP/AISDataHandler/2023/AIS_2023_06_04.zip
 - https://coast.noaa.gov/htdata/CMSP/AISDataHandler/2023/AIS_2023_06_05.zip
 - https://coast.noaa.gov/htdata/CMSP/AISDataHandler/2023/AIS_2023_06_06.zip
 - https://coast.noaa.gov/htdata/CMSP/AISDataHandler/2023/AIS_2023_06_07.zip
- **Columnas de referencia** (verifican las exactas de sus archivos): **MMSI** (identificador del buque), **BaseDateTime**, **LAT**, **LON**, **SOG** (velocidad sobre el fondo, nudos), **COG** (rumbo),

Heading, VesselName, IMO, CallSign, VesselType (código), Status, Length, Width, Draft, Cargo, TransceiverClass.

- **Recursos complementarios:**
 - **World Port Index** (puertos del mundo): disponible desde la misma página del dataset (<https://hub.marinecadastre.gov/pages/vesseltraffic>); también se acepta cualquier otra fuente de puertos, citada en el README.
 - Los códigos de **VesselType** corresponden a las categorías de tipo de buque del estándar AIS; su descripción está en la documentación del dataset.
- Estos son **datos crudos de sensores**: traen problemas reales de la fuente. Detectarlos, cuantificarlos y documentarlos hace parte del trabajo.
- Para el análisis espacial pueden usar una **grilla regular**: celdas **H3** (con la librería **h3**) o simplemente redondear latitud/longitud a una rejilla fija. Cualquiera de las dos sirve si la justifican.

3. Entrega 1 — explorar, responder, almacenar bien

40% del proyecto (12% de la nota del curso) · Databricks Free Edition

Alcance: todo lo visto hasta la semana 7. No se requiere pipeline por capas, streaming ni ML en esta fase: **explorar, responder y almacenar de forma óptima para un propósito**.

#	Requisito	%
1	Ingesta documentada: descarguen los 7 días desde la fuente oficial dentro del notebook (con reintentos y verificación de integridad), descompriman en su Volume y lean los CSV con esquema explícito	15
2	Exploración y perfilamiento: posiciones por día, buques únicos, distribución por tipo de buque y tamaño; identifiquen y cuantifiquen los problemas de calidad que encuentren (posiciones fuera de rango, velocidades imposibles, identificadores anómalos, duplicados, etc.). Ese diagnóstico es la materia prima de la Entrega 2	20
3	Preguntas de negocio. Respondan las 5 preguntas con Spark eficiente y justifiquen sus decisiones técnicas con el plan de ejecución:	25
	a. ¿Cuántos buques distintos transmitieron cada día? Comparen el conteo exacto con <code>approx_count_distinct</code> y argumenten cuál usarían en producción.	
	b. ¿Qué tipos de buque generan más tráfico? Top 10 por número de posiciones, con velocidad media por tipo (usen el catálogo de tipos).	
	c. ¿Qué 10 buques recorrieron más distancia durante la semana? (orden por buque y tiempo, distancia entre posiciones consecutivas con haversine).	

#	Requisito	%
	d. ¿Dónde se concentra el tráfico? Top 10 celdas de una grilla espacial (H3 resolución 8, o su propia rejilla lat/lon) por número de posiciones, y cuáles de esas celdas corresponden a puertos del World Port Index.	
	e. ¿Qué proporción de los buques de la semana transmitió los 7 días? ¿Dónde están los "visitantes de un solo día"?	
4	Almacenamiento óptimo para un propósito: declaren un propósito de consulta concreto (ejemplo: "la consulta diaria del operador, que filtra por fecha y zona marítima"), elijan formato de archivo y de tabla (Parquet vs Delta) y layout (particionamiento, <code>CLUSTER BY</code>), y demuestren la mejora con evidencia: bytes antes/después, archivos leídos por cada consulta (plan o <code>INPUT_FILE_NAME</code>) y efecto de <code>OPTIMIZE</code>	25
5	Gobernanza básica: organicen su trabajo en Unity Catalog (catálogo y esquemas propios) y dejen comentarios y metadatos en sus tablas	10
6	Repositorio y bitácora: repositorio con los notebooks documentados, README y bitácora con el aporte de cada clase	5

Fechas: el proyecto se publica el sábado 12 de septiembre. **Entrega 1: viernes 25 de septiembre, 23:59** (enlace al repositorio del grupo). Esta entrega no lleva sustentación: la única sustentación del proyecto es la final, en la última clase.

5. Recomendaciones

- **Serverless tiene límites:** `cache()`/`persist()` no están disponibles en Free Edition (los verán de nuevo en el clúster real). Ante la duda, consulten qué sí funciona.
- Los zip no se leen directamente con Spark: primero descompriman en su Volume.
- Toda decisión técnica se justifica con **evidencia** (planes de ejecución, bytes, archivos leídos), no con opiniones. "Lo hice porque es más rápido" no es un argumento.
- Trabajen de forma incremental: cada clase aporta una pieza del proyecto y la bitácora es la evidencia de ese avance continuo.
- El diagnóstico de calidad de la Entrega 1 es el insumo de las reglas de la Entrega 2: cuanto mejor lo documenten ahora, más fácil les será después.

6. Reglas del juego

- **Grupos de 3 estudiantes.** En la sustentación final cada integrante debe poder explicar cualquier parte del proyecto (hay evaluación individual).
- La entrega se hace con el **Bloque Neon**.

- La calidad de forma y contenido (documentación, estándares, redacción) hace parte de la calificación.